Natural Language Processing

อ. ปรัชญ์ ปิยะวงศ์วิศาล

Pratch Piyawongwisal

Recap: Artificial Neural Network

- เป็น supervised learning ใช้ทำ classification เป็นหลัก
- ข้อดี
  - ความแม่นยำสูงมาก
  - สามารถนำไปประยุกต์ใช้กับปัญหาที่มีความซับซ้อนได้มากมาย
  - เหมาะกับงานประมวลผลภาพ
- ข้อเสีย
  - ต้องการข้อมูลจำนวนมหาศาล
  - cost function ไม่ convex (มี minima ได้หลายจุด) ดังนั้นการเลือก initialize ค่าพารามิเตอร์เริ่มต้นจึงมีผลต่อคำตอบสุดท้ายของ gradient descent
  - เป็น black box model ตีความ/อธิบายที่มาที่ไปได้ยาก (ตรงข้ามกับ decision tree)

Today

- Natural Language Processing
  - Goal and history
  - Rule-based vs statistical approach
  - NLP tasks and pipeline
  - N-gram, TF-IDF
  - Word embeddings

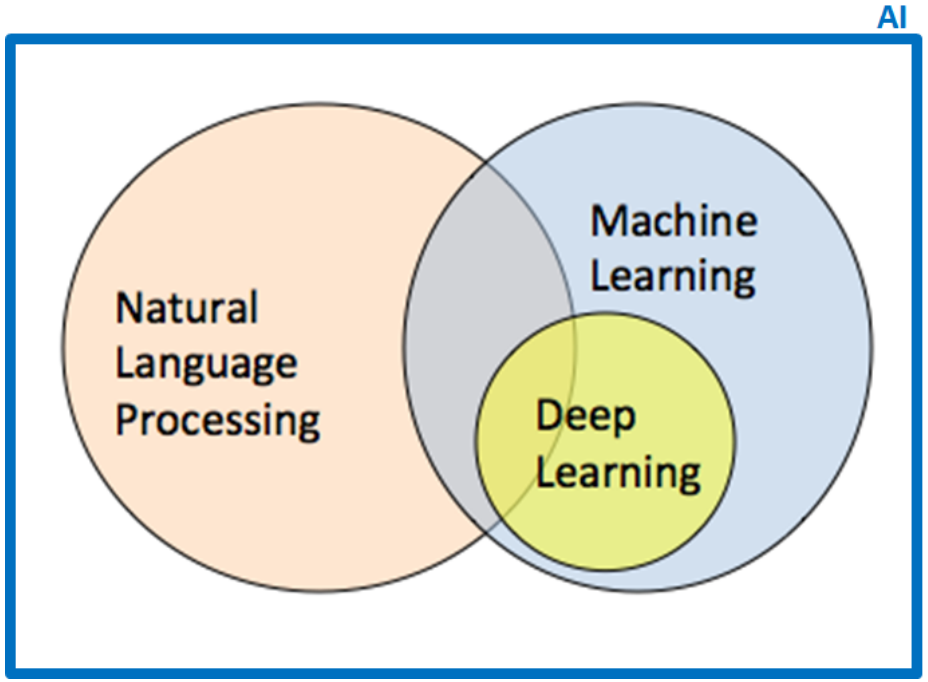

Natural Language Processing

- goal: understanding human language
- history
  - ก่อนปี 1980s ระบบ NLP ส่วนมากเป็นแบบ **rule-based** คือพัฒนาโดยการเขียนกฎเกณฑ์ต่าง ๆ (เกี่ยวกับความหมาย, ไวยากรณ์) ด้วยมือ
    - แตกปัญหาการเข้าใจภาษาแบบ high-level ออกเป็น low-level task ย่อยๆ
    - เช่น ระบบสนทนา chatbot ต้องประกอบด้วย โปรแกรมตัดคำ โปรแกรมแปลความหมายคำ โปรแกรมถอดโครงสร้างไวยากรณ์
  - ปลาย 1980s เริ่มหันมาใช้วิธีการทางสถิติ (**statistical approach**) มากขึ้น
    - ML algorithms (e.g. decision trees)
    - part-of-speech tagging โดยใช้ Hidden Markov Model (HMM)
  - ช่วงปี 2010s พบว่าสามารถใช้ Deep Neural Network ทำงาน NLP ต่าง ๆ ได้ผลดีเยี่ยมเป็น state-of-the-art
    - นิยมใช้เทคนิค word embeddings เพื่อ capture ความหมายของคำในภาษา
    - เริ่มสามารถแก้ปัญหา high-level ได้เลย โดยไม่ต้องแตกเป็น task ย่อย

Natural Language Processing

- เปรียบเทียบ rule-based vs statistical NLP
  - statistical NLP ทนต่อความหลากหลาย (variation) ของภาษาได้ดีกว่าแบบ rule-based
    - คำที่ไม่เคยพบมาก่อน
    - คำที่สะกดผิด
    - คำที่หายไป
    - ความถี่ในการใช้คำ
  - statistical NLP สามารถวิวัฒนาการไปตามข้อมูลที่มี ยิ่งป้อนข้อมูลให้มากเท่าใด ยิ่งเก่งขึ้นเท่านั้น ในขณะที่แบบ rule-based ต้องสร้างกฎให้ซับซ้อนขึ้นเรื่อย ๆ ซึ่งยาก
  - statistical NLP ต้องพึ่งแรงงานคนในการ label ข้อมูลสำหรับการ train

NLP tasks

- Syntax
  - grammar induction
  - stemming/lemmatization
  - part-of-speech tagging
  - parsing
  - word segmentation
- Semantics
  - lexicon/semantic networks
  - machine translation
  - sentiment analysis
  - topic segmentation
  - question answering

เกี่ยวกับ**ไวยากรณ์**

เรียนรู้กฎไวยากรณ์

ลดรูปคำ เช่น studied -> study

แท็กประเภทคำ เช่น noun, verb, adj

แปลงประโยคเป็นโครงสร้างแกรมมาแบบ tree

ตัดคำ (เฉพาะบางภาษา)

เกี่ยวกับ**ความหมายของคำ**

หาความสัมพันธ์ระหว่างคำ

แปลภาษา

วิเคราะห์ความรู้สึก

แบ่งเอกสารตามหัวข้อ

ถาม-ตอบ

NLP pipeline

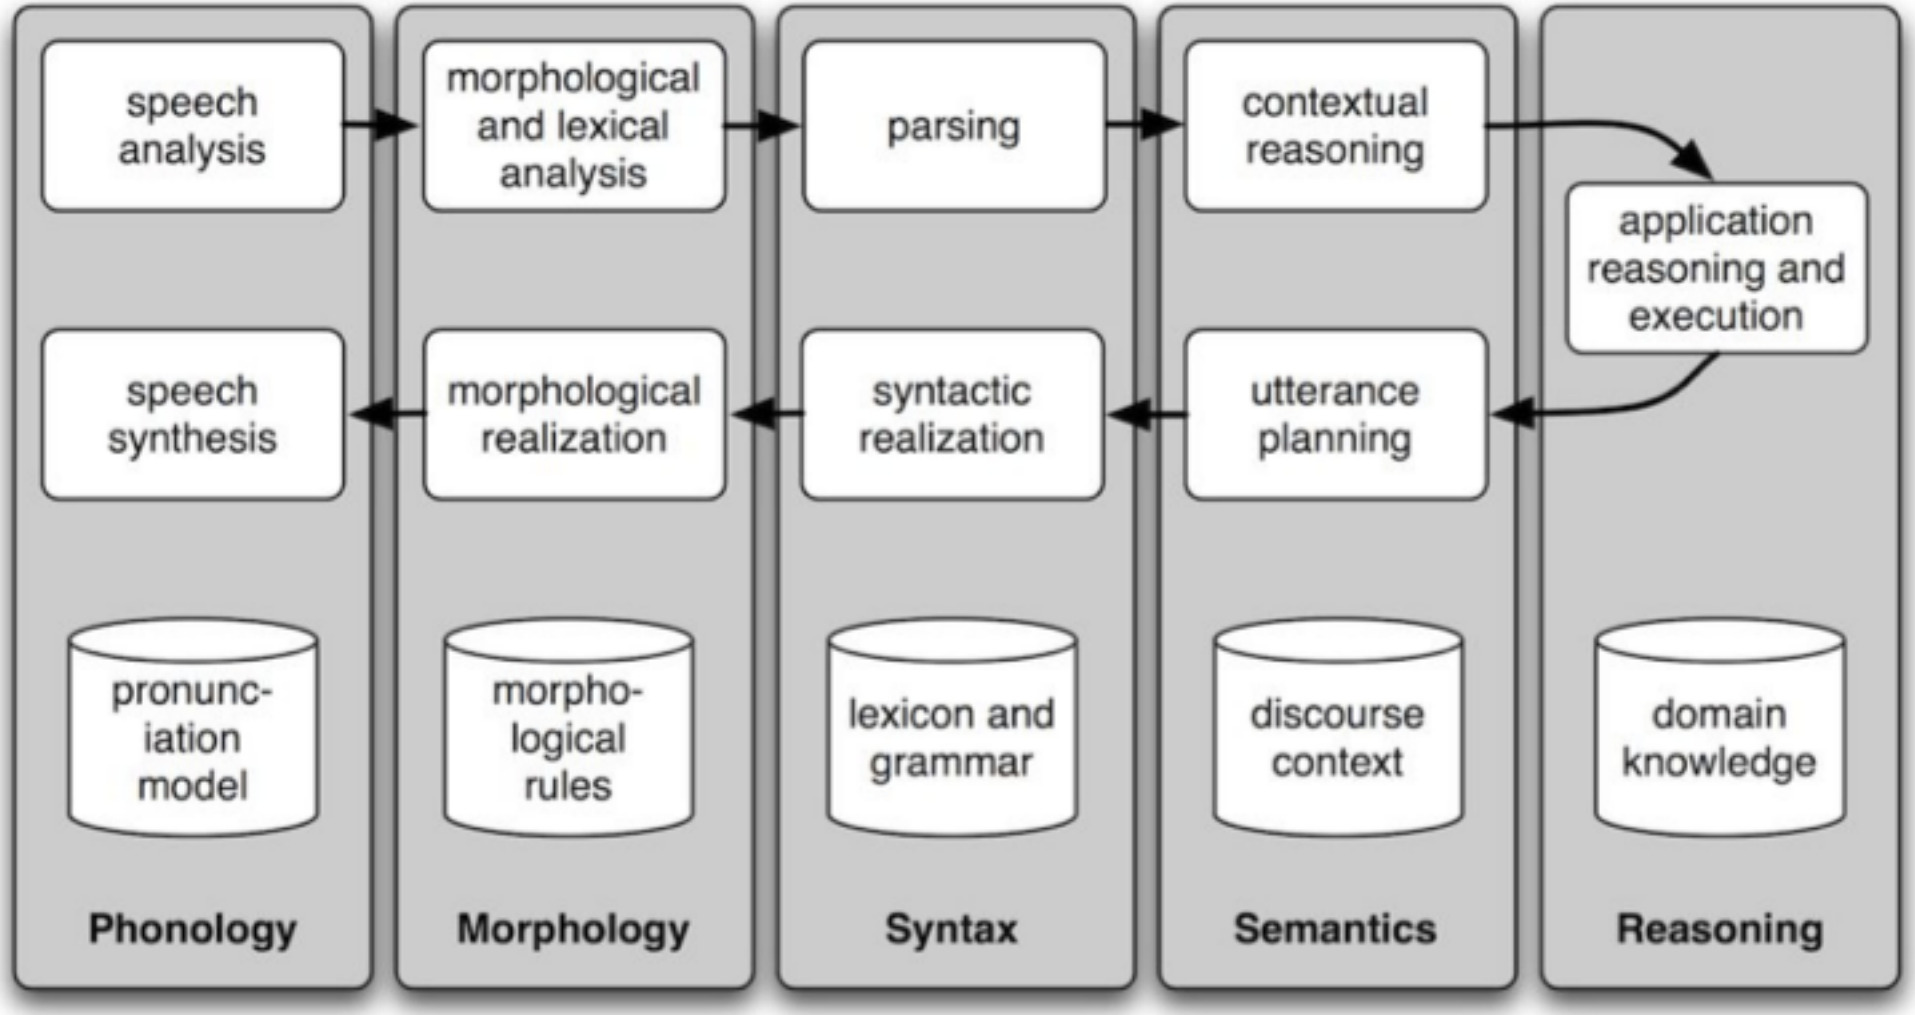

NLP pipeline

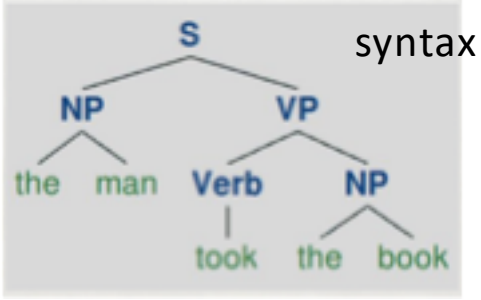

syntax structure

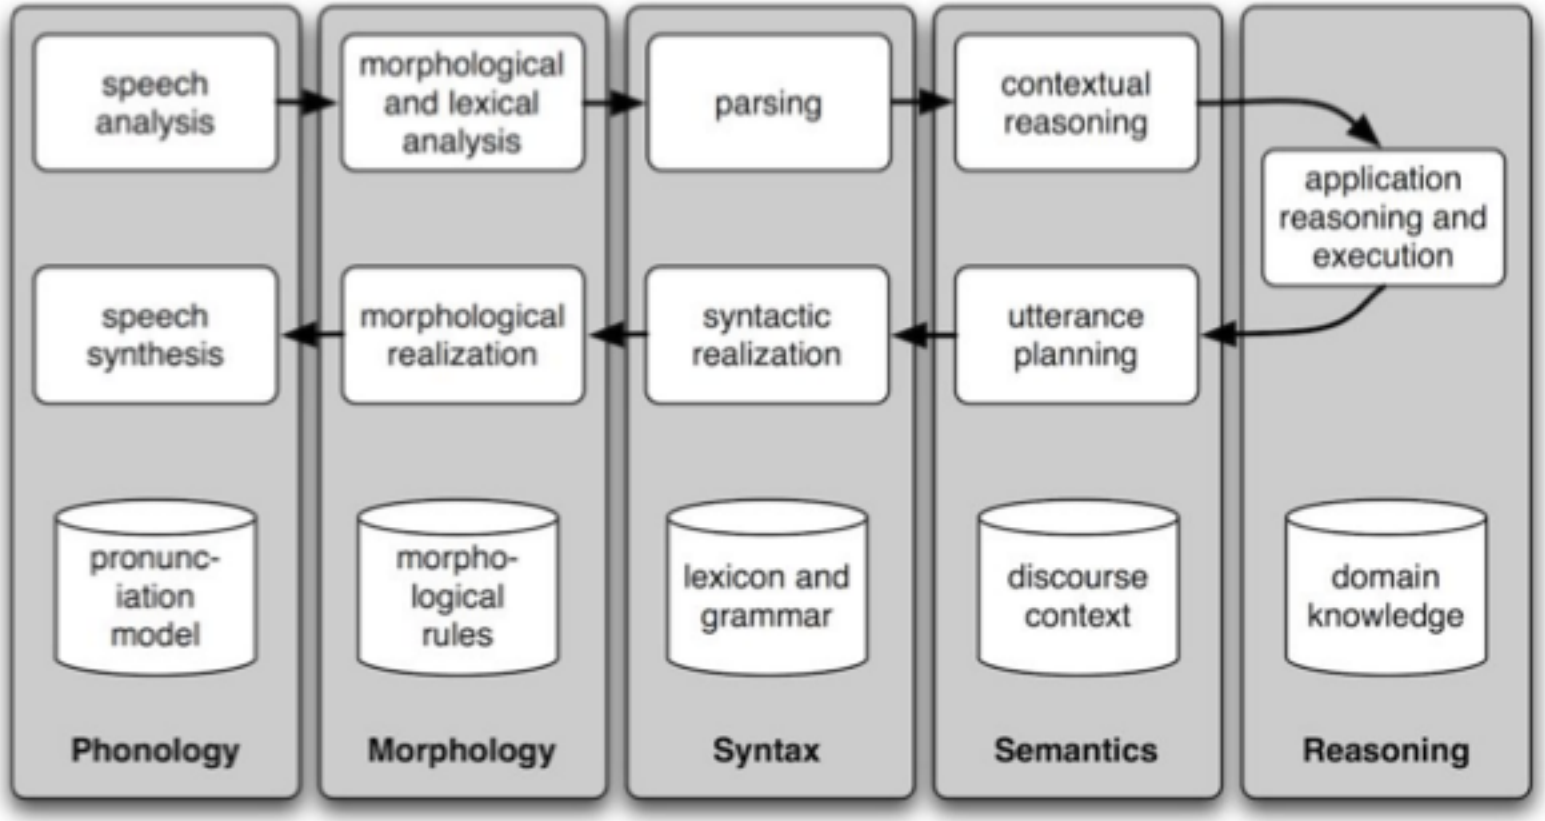

Stemming
Lemmatization
Segmentation

grammar
parsing
part-of-speech

semantic web
topic
sentiment
knowledge

NLP - Data Science vs AI/ML Research

- ในฐานะของนักวิจัย AI/ML งานทาง NLP คือ การออกแบบโมเดลหรืออัลกอริทึมที่สามารถทำ NLP task ต่าง ๆ ได้อย่างถูกต้องและแม่นยำ

- ในขณะเดียวกัน -

- ในฐานะของนัก Data Scientist/Engineer งานทาง NLP จะเน้นการประมวลข้อมูล raw text (ดูดมาจากเว็บหรือฐานข้อมูล) เพื่อสกัดเอาข้อมูลที่มีค่าออกมา แล้วนำมาสร้างเป็น Application หรือเพื่อตอบคำถามอะไรสักอย่าง
  - เช่น หา sentiment ของลูกค้าต่อ product โดยดูจาก comment ใน Facebook

Python NLP libraries

- NLTK
- TextBlob
- Spacy
- Gensim
- Stanford's CoreNLP
- BeautifulSoup

Text Classification problem

- ปัญหา text classification แบบ supervised คือการหาฟังก์ชัน f : Docs->labels เช่น
  - f : UserComments -> {happy, sad}
  - f : NewsArticles -> {economics, politics, sport}
- ลักษณะของฟังก์ชัน f ขึ้นกับ model ที่เราเลือกใช้ เช่น
  - Naïve Bayes
  - SVM
  - Neural Network

Lab: Text Classification (20newsgroup dataset)

https://towardsdatascience.com/machine-learning-nlp-text-classification-using-scikit-learn-python-and-nltk-c52b92a7c73a

- ใช้ SVM
- ใช้ค่า TF-IDF ของคำ บ่งบอกถึงความสำคัญของคำนั้น ต่อเอกสารนั้น
  - TF(Term Frequency) = ความถี่ของคำที่พบในเอกสารนั้น
  - IDF(Inverse Document Frequency) = อินเวอร์สของความถี่ของคำในทุกเอกสารใน corpus
- training data คือค่า TD-IDF ของทุกคำในทุกเอกสาร
  - เก็บในรูปของ document term matrix

Word Representation

- Solution 1: represent word ด้วย one-hot vector ขนาด n
  โดยที่ n คือจำนวนคำศัพท์ทั้งหมดใน dictionary
  - dog -> [0 0 0 1 …….. 0 0 0]
  - loves -> [1 0 0 0 …….. 0 0 0]
  - coffee -> [0 0 0 0 …….. 0 1 0]
- represent document ด้วย Bag-of-Words
  - dog loves coffee -> [1 0 0 1 …….. 0 1 0]

- **ข้อเสีย:** ไม่นับจำนวนครั้งที่ปรากฏ, ลำดับก่อนหลังไม่มีผล, ไม่บ่งบอกถึงคำที่คล้ายกัน

Word Representation

- Solution 2: ใช้ Word Embedding (word2vec)
  - represent word ด้วย vector ขนาดเล็ก (เช่น ขนาด 300)
  - ต้องการให้คำที่คล้ายคลึงกัน มี vector ดังกล่าวที่คล้ายกันด้วย
  - ใช้ Neural Network ในการหา
  - อ่านเพิ่มเติมที่ https://www.tensorflow.org/tutorials/representation/word2vec

Lab:

- ใช้ pre-trained word embedding จาก Google News
  - https://drive.google.com/uc?id=0B7XkCwpI5KDYNlNUTTlSS21pQmM&export=download
- ทำตามอาจารย์

Machine Translation with Encoder-Decoder Network (seq2seq)

- https://google.github.io/seq2seq/

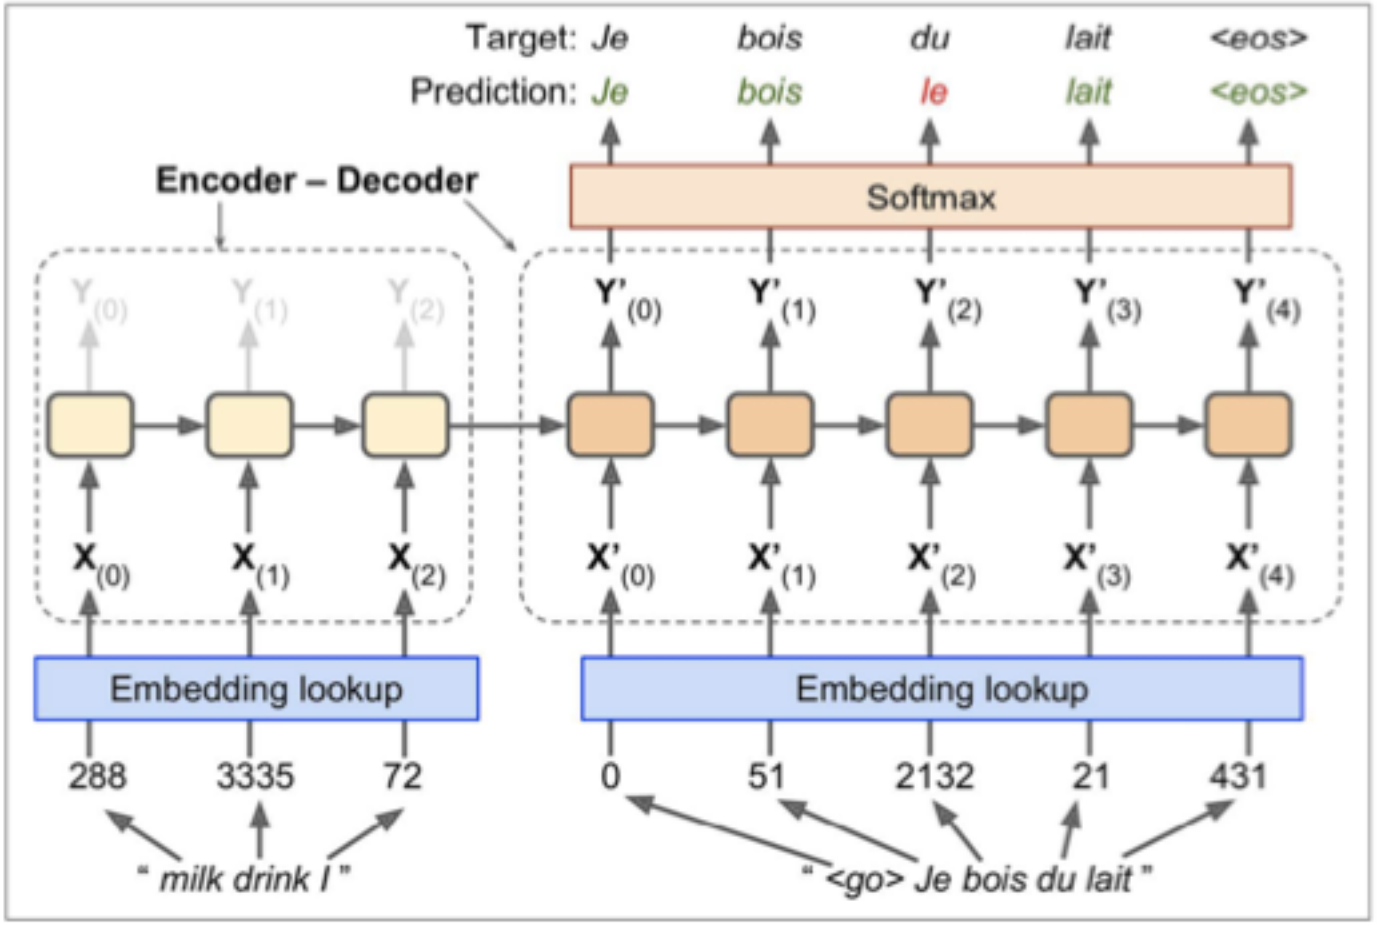

Interesting Applications

- Generating fake YouTube comments with char-RNN
  - https://www.youtube.com/watch?v=oJeQvjJmKQ8