

# Logistic Regression

อ. ปรัชญ์ ปิยะวงศ์วิศาล

Pratch Piyawongwisal

# Today

- ~~Midterm Solution~~
- Recap - Linear Regression
  - Minimizing cost function
  - Solutions
    - Normal Equation
    - (Stochastic) Gradient Descent
  - Polynomial Regression
  - Regularization -> solves overfitting
- Logistic Regression

# Recap: Supervised Learning

- Classification

kNN

- Predicts class labels/categories

Logistic

- ทำนายค่าที่เป็นหมวดหมู่ = จำแนกประเภท

Regression

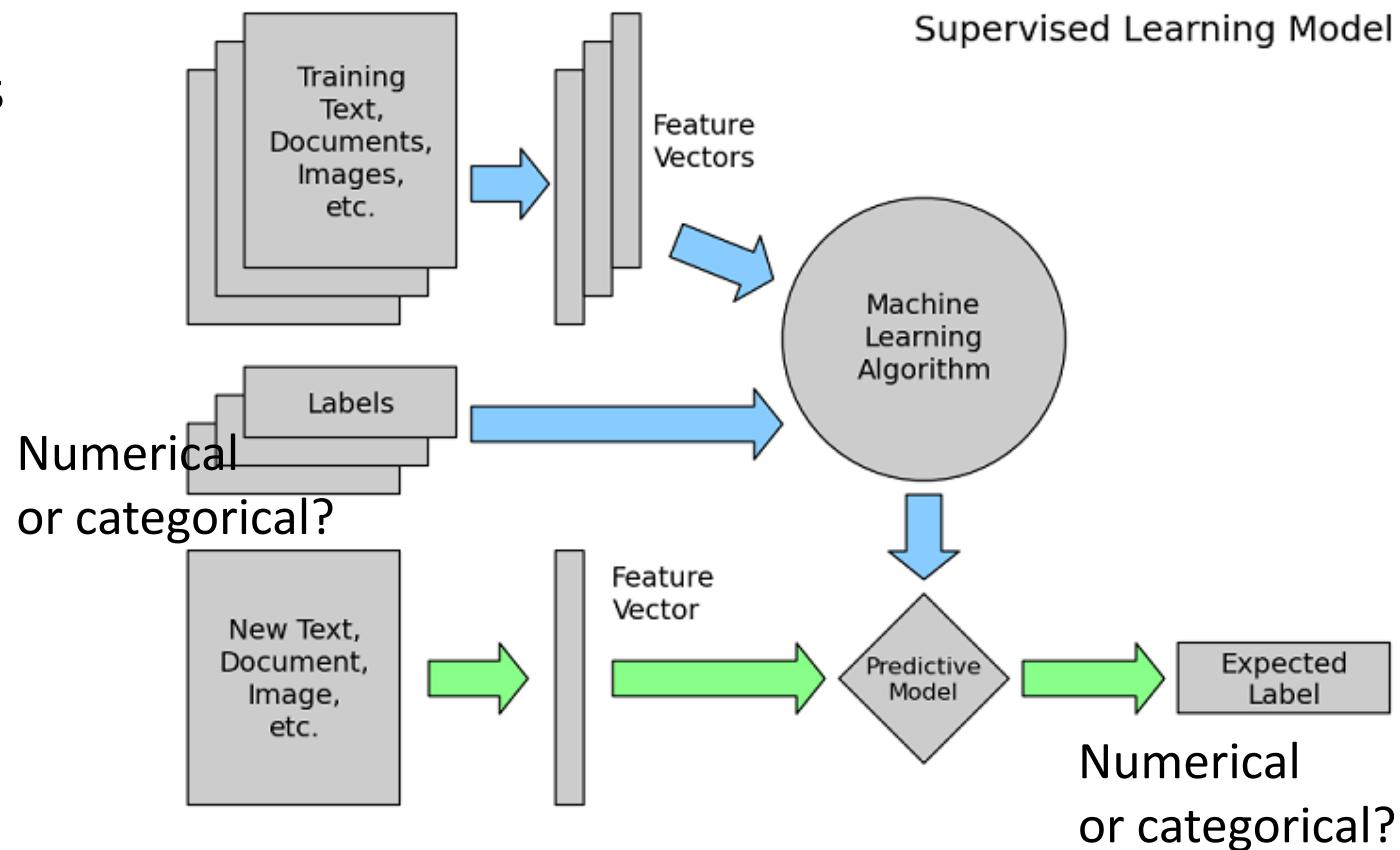
- อาจมองเป็นการหา boundary ที่แบ่งข้อมูลในแต่ละหมวดหมู่ ออกจากกัน

- Regression

- Predicts continuous values

Linear  
Regression

- ทำนายค่าที่เป็นจำนวนจริง
- อาจมองเป็นการหา hyperplane ที่ fit กับข้อมูลที่มีมากที่สุด



# Linear Regression - Summary

- Regression: หาโมเดลที่ fit กับข้อมูลได้ดีที่สุดได้อย่างไร?

- โมเดล:  $\hat{y} = h_{\theta}(x) = \underline{\theta^T x}$

- cost function ของโมเดล: mean-square error (MSE)

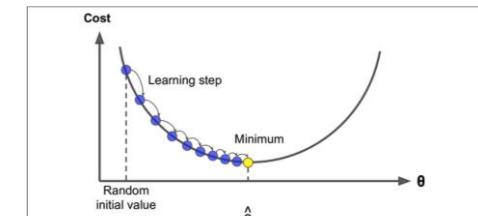
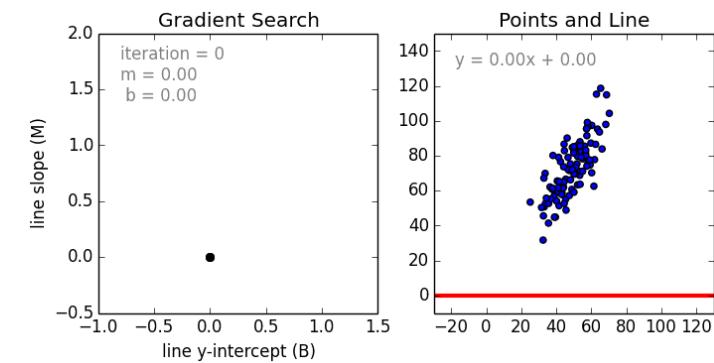
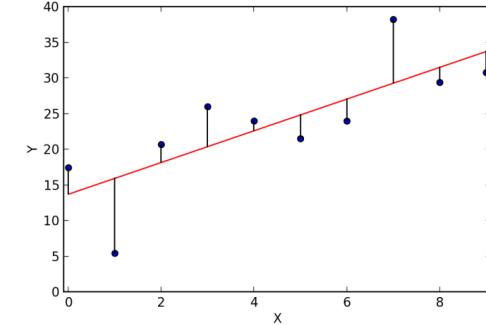
$$J(\underline{\theta}) = MSE(\theta) = \frac{1}{M} \sum_{i=1}^M (\underline{\theta^T x^{(i)}} - \underline{y^{(i)}})^2$$

- การ train โมเดล คือ การหาค่าของ  $\hat{\theta}_{MSE} = \underset{\underline{\theta}}{\operatorname{argmin}} J(\theta)$

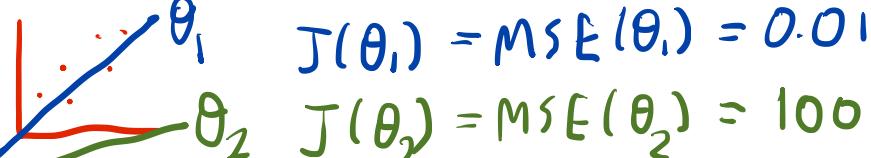
- Solution 1: แก้สมการตรง ๆ จะได้ Normal equation:  $\hat{\theta}_{MSE} = (\underline{\underline{x^T \cdot x}})^{-1} \cdot \underline{\underline{x^T \cdot y}}$

- Solution 2: หรือใช้วิธี Gradient Descend โดยค่อยๆ update  $\theta$ :

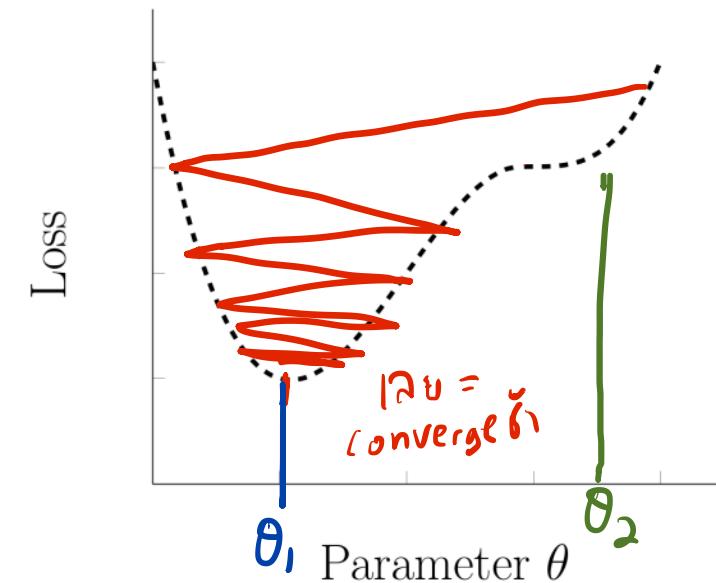
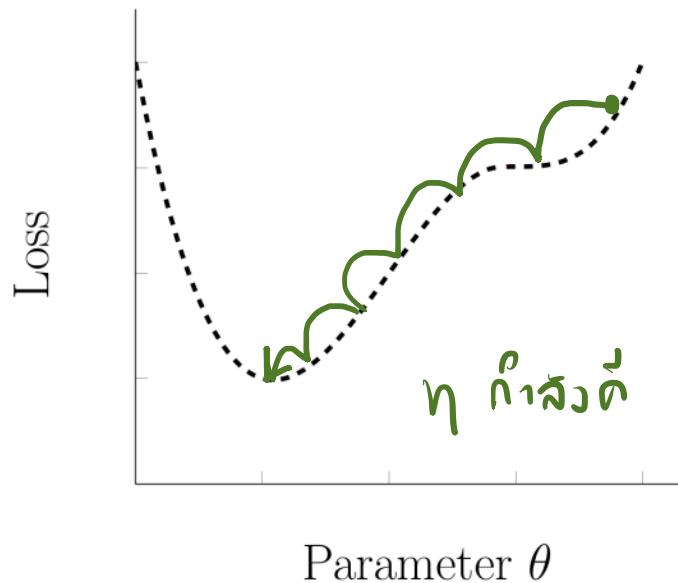
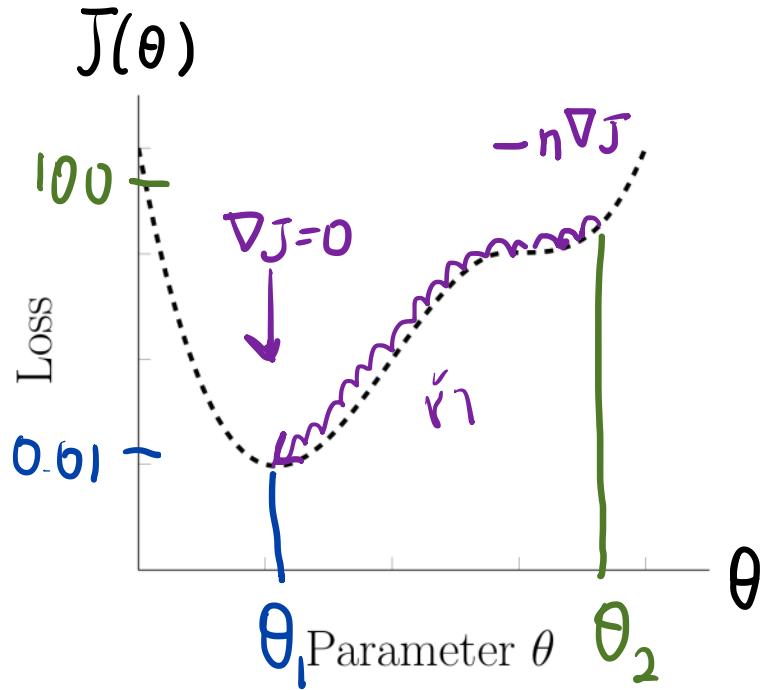
$$\theta^{(\text{next step})} = \theta - \boxed{\eta} \nabla_{\theta} MSE(\theta)$$



ภูเข้า MSE


 $J(\theta_1) = \text{MSE}(\theta_1) = 0.01$   
 $J(\theta_2) = \text{MSE}(\theta_2) = 100$   
 hyperparam

# How to choose the learning rate $\eta$ ?



low  $\eta = 0.1$

$\theta_{\text{current}}$   
 $\theta_{\text{next step}} = \theta - \eta \nabla_{\theta} \text{MSE}(\theta)$   
 learning rate

high  $\eta = 10$

# Exercise: Housing Price Prediction

- ข้อมูล training

ขนาด (Sq. ft.)	จำนวน ห้องนอน	ระยะทางไป ห้างสรรพสินค้า	ราคา (ล้านบาท)
1000	2	5	9.5
1500	3	30	8.0
2000	5	40	12.5
1700	1	5	9.0
1200	2	30	5.5

โมเดล Linear Regression (ราคาสำหรับ 1 หลัง) คือ  
 $h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3$

เราสามารถเขียนข้อมูลในรูป matrix (สำหรับ m หลัง) ได้ดังนี้

$$X = \begin{bmatrix} 1 & 1000 & 2 & 5 \\ 1 & 1500 & 3 & 30 \\ 1 & 2000 & 5 & 40 \\ 1 & 1700 & 1 & 5 \\ 1 & 1200 & 30 & 5.5 \end{bmatrix} \quad y = \begin{bmatrix} 9.5 \\ 8.0 \\ 12.5 \\ 9.0 \\ 5.5 \end{bmatrix}$$

โมเดลในรูป matrix:  $\hat{y} = X\theta$

จากนั้นคำนวณหา  $\hat{\theta}_{MSE}$  โดยใช้ normal equation:

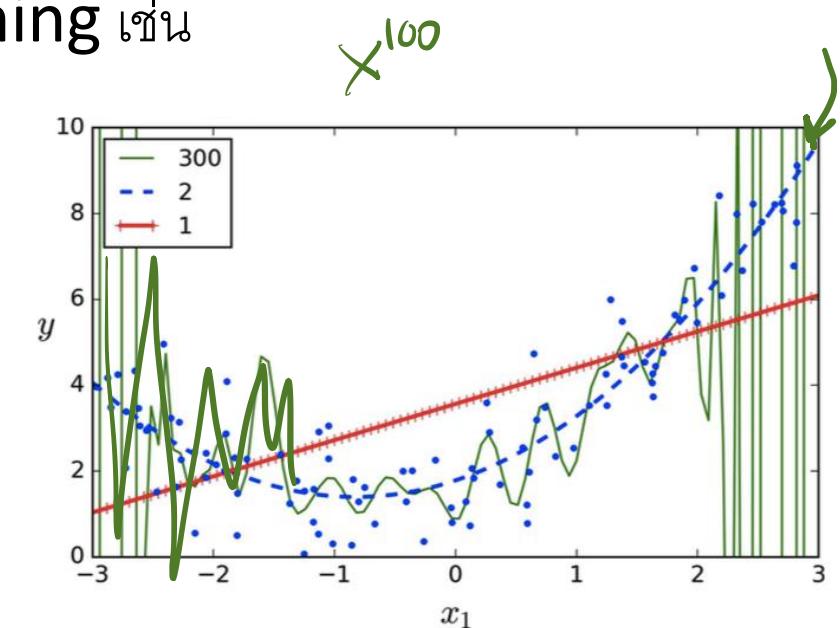
$$\hat{\theta}_{MSE} = (X^T \cdot X)^{-1} \cdot X^T \cdot y$$

# Polynomial Regression, Regularization

- สามารถทำ Polynomial Regression โดยเพิ่มมิติข้อมูล training เช่น
  - $x_i$  เดิม = [น้ำหนัก, ส่วนสูง, อายุ] = [70, 150, 30]
  - $x_i$  ใหม่ = [70, 150, 30,  $70^2$ ,  $150^2$ ,  $30^2$ ]
- แต่ถ้า poly degree สูงไปอาจทำให้ overfit ☹
- Solution: เพิ่มพจน์ regularization ใน cost function

$$J(\theta) = \text{MSE}(\theta) + \alpha \frac{1}{2} \sum_{i=1}^n \theta_i^2$$

Ridge (L2) regularization



พยายามลดอิทธิพลของ polynomial degree สูงๆ อย่าง  $x^4, x^5$  = ลด overfitting

# Logistic Regression

# Linear Regression

How to apply?

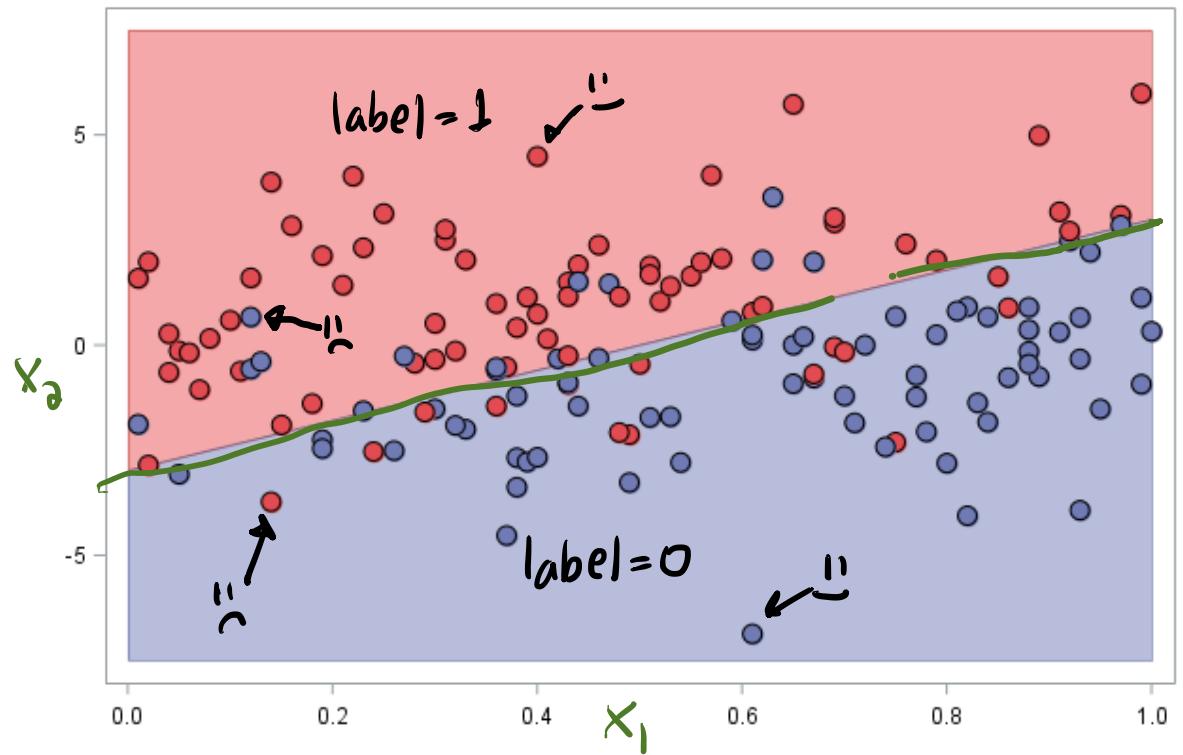
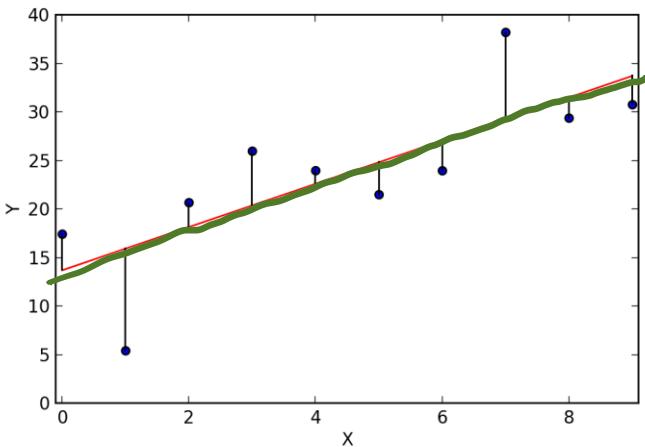
# → (Binary) Classification

## Linear Regression

- Input:  $x$  คือ input features
- Output:  $\hat{y}$  เป็นจำนวนจริง

โมเดล:  $\hat{y} = h_{\theta}(x) = \underline{\theta^T x}$

- ความสัมพันธ์แบบ linear

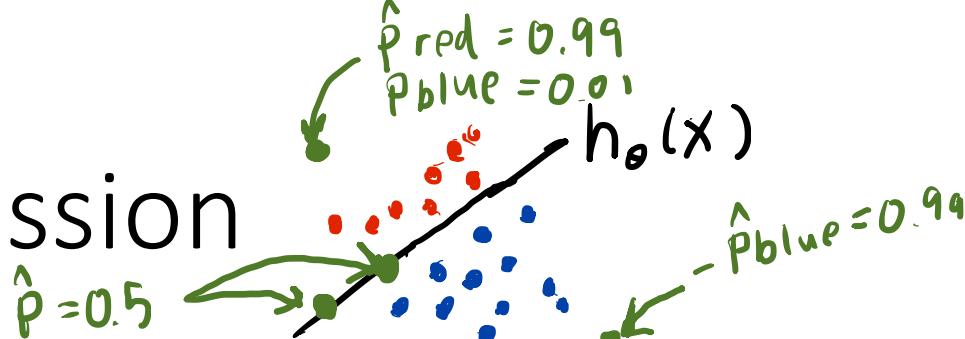


พิจารณาปัญหา binary classification เช่น

- อีเมลเป็น spam ( $label=1$ ) หรือไม่เป็น สแปม ( $label=0$ )
- คนใช้เป็นมะเร็ง ( $label=1$ ) หรือไม่เป็นมะเร็ง ( $label=0$ )

\*  $\hat{p}$  คือค่าเป็นความน่าจะเป็น

# Logistic Regression



- **Key Idea:** เราต้องการให้มีโมเดล  $h_\theta(x)$  ทำนายค่าความน่าจะเป็นที่ **label** จะเป็น 1
- $\hat{p}(y = 1|x; \theta)$
- $\hat{p}(y = 0|x; \theta)$  ความน่าจะเป็นที่ **label** จะเป็น 0
- จากนั้นเราสามารถใช้ค่าของ  $\hat{p}$  ในการ **classify** ข้อมูลด้วยกฎง่ายๆ นี้ได้

$$\hat{y} = \begin{cases} 0 & \text{if } \hat{p} < 0.5, \\ 1 & \text{if } \hat{p} \geq 0.5. \end{cases}$$

$\uparrow$   
classification output

ใช้ นำพบว่า

$\hat{p}(y = \text{red} | x) = 0.9$   
 $\hat{p}(y = \text{blue} | x) = 0.1$

มาก

↓  
decision

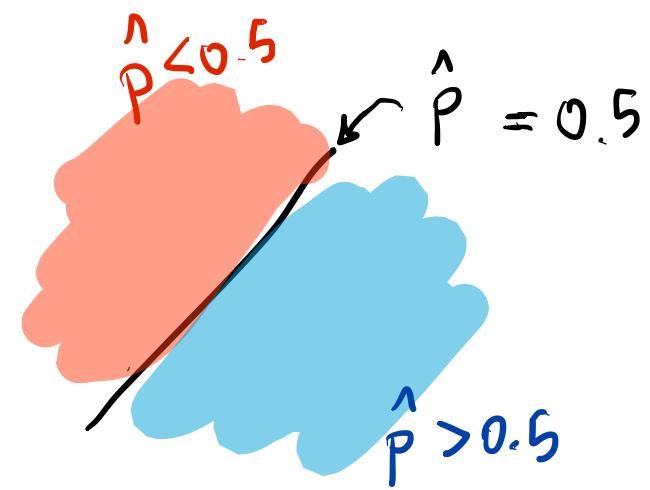
$\hat{P}_{\text{red}} = 0.9 > 0.5$   
ดังนั้นจึง classify ให้  $x$   
กับ label เริ่ม  $\hat{y} = \text{red}$

# Logistic Regression

- **Key Idea:** เราต้องการให้มีโมเดล  $h_{\theta}(x)$  ทำนายค่า
  - $\hat{p}(y = 1|x; \theta)$  ความน่าจะเป็นที่ **label** จะเป็น 1
  - $\hat{p}(y = 0|x; \theta)$  ความน่าจะเป็นที่ **label** จะเป็น 0
- Q: ใช้  $h_{\theta}(x)$  เดียวกันกับ Linear Regression เลยได้ไหม?

$$\hat{p}(y = 1|x; \theta) = h_{\theta}(x) = \theta^T x$$

  
Linear Regression  
ok?



# Logistic Regression

- **Key Idea:** เราต้องการให้มोเดล  $h_{\theta}(x)$  ทำนายค่า
  - $\hat{p}(y = 1|x; \theta)$  ความน่าจะเป็นที่ **label** จะเป็น 1
  - $\hat{p}(y = 0|x; \theta)$  ความน่าจะเป็นที่ **label** จะเป็น 0
- Q: ใช้  $h_{\theta}(x)$  เดียวกันกับ Linear Regression เลยได้ไหม?  
$$\hat{p}(y = 1|x; \theta) = h_{\theta}(x) = \boldsymbol{\theta}^T \mathbf{x}$$
- ปัญหา: ความน่าจะเป็นต้องมีค่าในช่วง 0-1 เท่านั้น ในขณะที่  $\boldsymbol{\theta}^T \mathbf{x}$  มีค่าเป็นเท่าใดก็ได้ 😔

# Sigmoid Function $\sigma(x)$

- Solution: เปลี่ยน model เป็น

$$\hat{p} = h_{\theta}(x) = \sigma(\theta^T x)$$

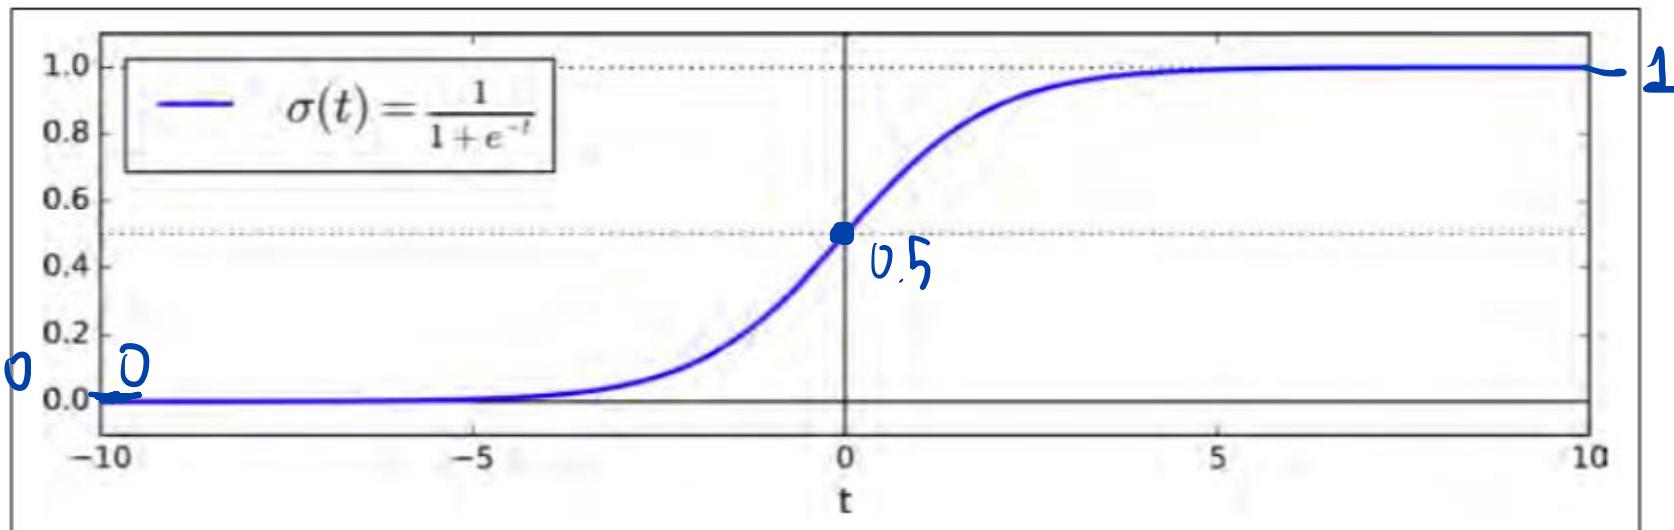
- โดยที่  $\sigma(t)$  คือ logistic (sigmoid) function

$$\sigma(t) = \frac{1}{1 + \exp(-t)}$$

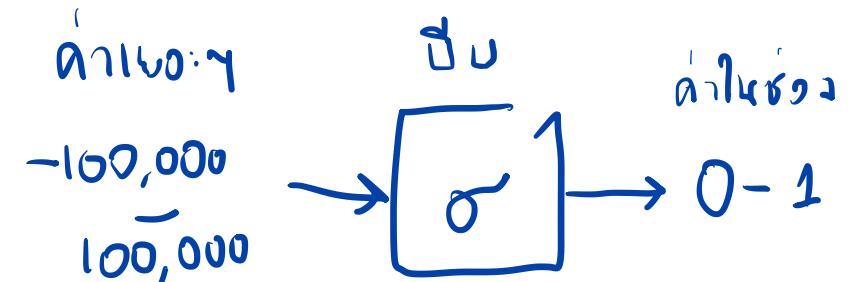
$$\frac{1}{1+e^0} = \frac{1}{2}$$

$$\frac{1}{1+e^{-\infty}} = \frac{1}{1+0} = 1$$

→



$$\frac{1}{1+e^{(-\infty)}} = \frac{1}{e^0} = 0$$



binary  
binary classification  $\hat{y} = 0, 1$

# Logistic Regression Model

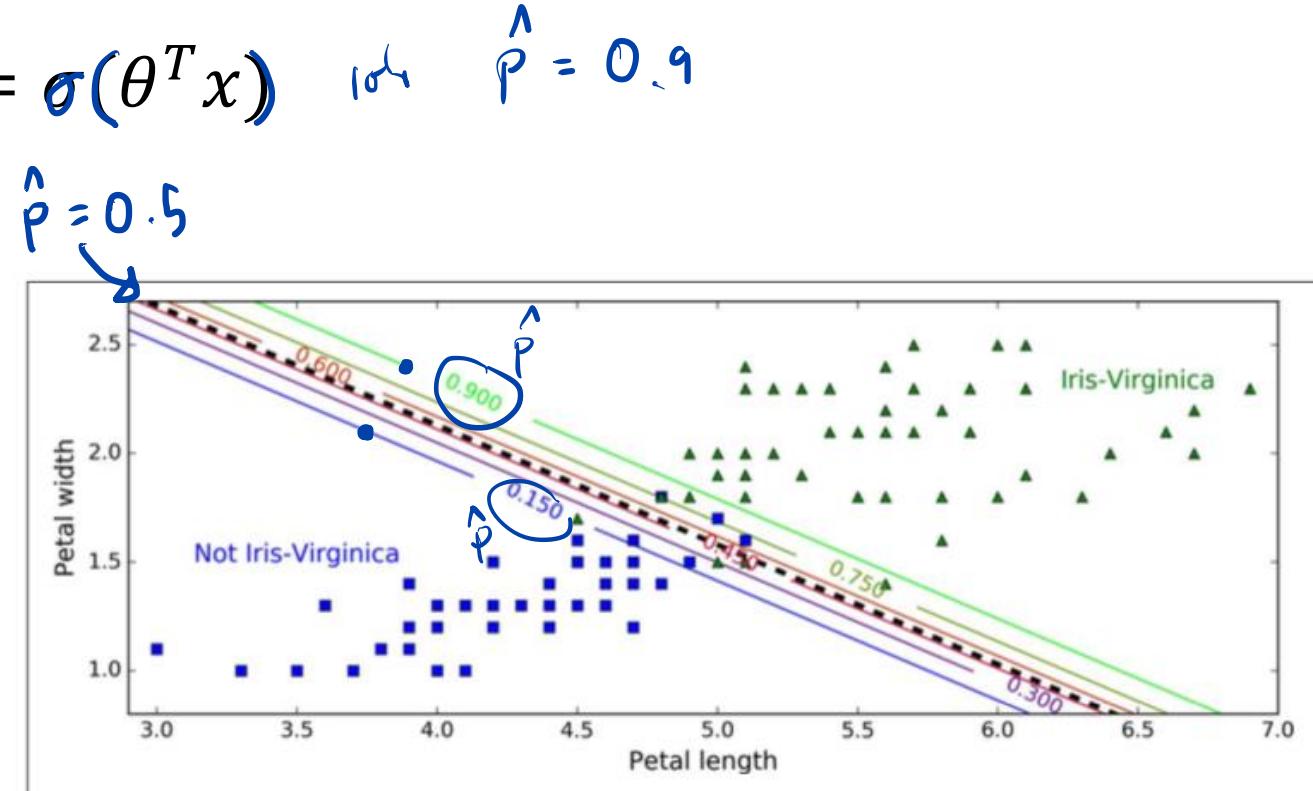
- โมเดล:  $\hat{p}(y = 1|x; \theta) = h_{\theta}(x) = \sigma(\theta^T x)$  ต่อ  $\hat{p} = 0.9$

- กฎการตัดสินใจ **decision rule**

$$\hat{y} = \begin{cases} 0 & \text{if } \hat{p} < 0.5, \\ 1 & \text{if } \hat{p} \geq 0.5. \end{cases}$$

- โดยที่

- Input:  $x$  คือ input features
- Output:  $\hat{y}$  เป็น binary (0/1)



ตัวอย่าง **decision boundary** จากการใช้วิธี logistic regression

ໄຈ ມີເງິນໃຫຍ່  $c_{\text{เดົນ}}(\theta) = (h_{\theta}(x) - y)^2$  ແທກ ດ້ວຍ regression ເກົ່ານີ້

# Cost Function

- cost function  $\downarrow$  ບັນບຸກດັ່ງກໍາຄວາມແຍ່ງຂອງ  $\theta$  (ຕະດູກ)
- cost ສໍາຮັບແຕ່ລະ instance ຂໍ້ມູນຄື່ອ

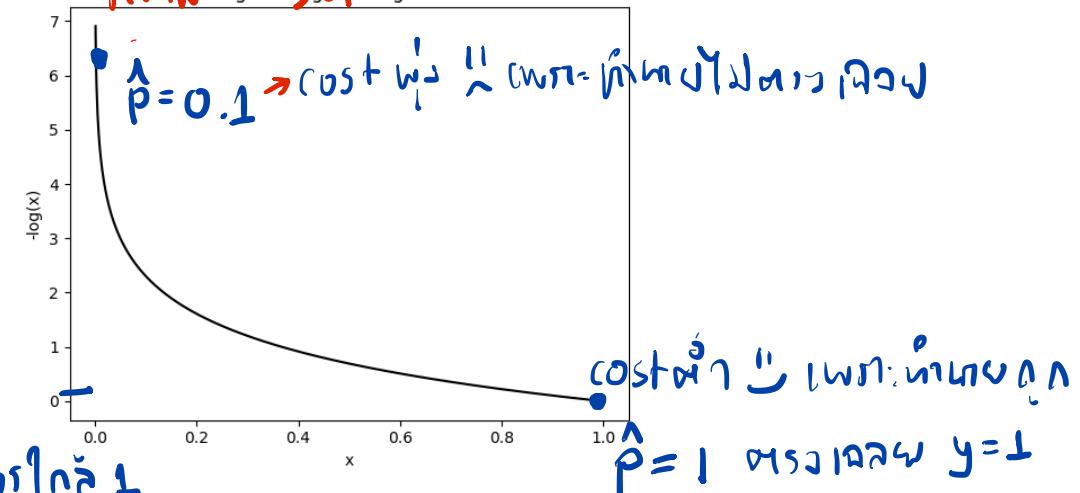
$$c(\theta) = \begin{cases} -\log(\hat{p}) & \text{if } y = 1, \\ -\log(1 - \hat{p}) & \text{if } y = 0. \end{cases}$$

$\xrightarrow{\text{label } \hat{y} \rightarrow \text{ກໍລວງໄກລ້ 1}}$

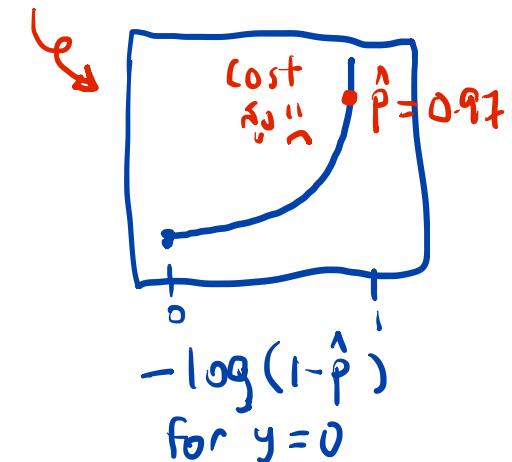
- ສູງໆນີ້ ທີ່ໃຫ້ cost ສູງ ເຈົາກໍາເຫັນ  $\hat{p}$  ຖື່ນມີ  $y=1$  ແລະ  $\hat{p}=1$  ໃຕ້ວໄຟ້ ບໍ່ເປັນ 0.97
- cost ສໍາຮັບທັງໝົດຂໍ້ມູນຈຶ່ງເປັນດັ່ງສມາກ

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(\hat{p}^{(i)}) + (1 - y^{(i)}) \log(1 - \hat{p}^{(i)})]$$

ເຊັ່ນໃຫຍ່ທີ່ດັ່ງນີ້  $c(\theta) = -y \log \hat{p} - (1-y) \log(1 - \hat{p})$



ໄອເດີຍຄື່ອ ຄໍ້າເຊີຍເປັນມະເງົາ ( $y=1$ )  
ແຕ່  $\hat{p}$  ທຳນາຍວ່າໄກລ້ 0 ດ່າວນ  $\text{cost} = -\log(\sim 0)$  ຈະໃໝ່ມາກ  
ຄໍ້າ  $\hat{p}$  ທຳນາຍວ່າໄກລ້ 1 ດ່າວນ  $\text{cost}$  ຈະເປັນ 0



# How to train?

- จะ train ไม่เดلنี้อย่างไร? (minimize cost อย่างไร?)

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[ y^{(i)} \log(\hat{p}^{(i)}) + (1 - y^{(i)}) \log(1 - \hat{p}^{(i)}) \right]$$

- ไม่มี closed-form solution แบบ Normal Eq 😞

# How to train?

- จะ train โมเดลนี้อย่างไร? (minimize cost อย่างไร?)

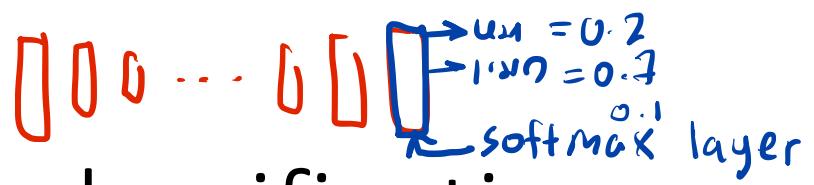
$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[ y^{(i)} \log(\hat{p}^{(i)}) + (1 - y^{(i)}) \log(1 - \hat{p}^{(i)}) \right]$$

- ไม่มี closed-form solution แบบ Normal Eq ☹
- แต่สามารถหา gradient/partial derivative ได้ ☺

$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{1}{m} \sum_{i=1}^m (\sigma(\theta^T \cdot \mathbf{x}^{(i)}) - y^{(i)}) x_j^{(i)} \implies \nabla_{\theta} J(\theta)$$

- ดังนั้นใช้วิธี Stochastic Gradient Descent แบบเดิมได้

update rule     $\theta_{\text{new}} = \theta - \eta \nabla_{\theta} J(\theta)$



# From Binary to Multi-class classification

- ข้อจำกัดของ Logistic Regression คือ สามารถใช้กับข้อมูลที่มี label เพียง 2 คลาสเท่านั้น
- หากต้องการ generalize ไปใช้กับ multi-class สามารถเปลี่ยนไปใช้ **softmax** function

$$\hat{p} = \sigma(\theta^T x) \Rightarrow \hat{p}_k = \sigma(s(x))_k = \frac{\exp(s_k(x))}{\sum_{j=1}^K \exp(s_j(x))}$$

ก็คือ ให้  $\hat{p}_k$  เป็นความน่าจะเป็นที่ตัวอย่าง  $x$  属于 คลาสที่  $k$

$$\begin{aligned}\hat{p}_{\text{sum}} &= \frac{e^{s_{\text{sum}}}}{e^{s_{\text{sum}}} + e^{s_{\text{binary}}} + e^{s_{\text{other}}}} \\ \hat{p}_{\text{binary}} &= \frac{e^{s_{\text{binary}}}}{\dots} \\ \hat{p}_{\text{other}} &= \frac{e^{s_{\text{other}}}}{\dots}\end{aligned}$$

- $K$  is the number of classes.
- $s(x)$  is a vector containing the scores of each class for the instance  $x$ .
- $\sigma(s(x))_k$  is the estimated probability that the instance  $x$  belongs to class  $k$  given the scores of each class for that instance.
- และ cost function จะเปลี่ยนเป็น Cross-Entropy ซึ่งจะเหมือน LR cost หาก  $k=2$

$$J(\Theta) = -\frac{1}{m} \sum_{i=1}^m \sum_{k=1}^K y_k^{(i)} \log (\hat{p}_k^{(i)})$$

2 class = binary

# Lab: ใช้ Logistic Regression จำแนกพันธุ์ดอกกล้วยไม้

```
from sklearn.linear_model import LogisticRegression
```



เป้าหมาย: จำแนก Iris-Virginica ออกจากชนิดอื่น โดยใช้ขนาดของกลีบ Sepal/Petal - width/length

# Next week

- Support Vector Machine (SVM)